

سری‌های زمانی

سری زمانی و تحلیل سری زمانی

- ▶ منظور از یک سری زمانی مجموعه‌ای از داده‌های آماری است که در فواصل زمانی مساوی و منظمی جمع‌آوری شده باشند.
- ▶ مثال: فروش ماهانه یک کارخانه طی سه سال گذشته
- ▶ مثال: میزان متوسط بارش سالیانه در کشور طی پنجاه سال گذشته
- ▶ تحلیل سری زمانی نیز یک از روش‌های تحلیل چنین داده‌هایی است.
- ▶ مثال: تشخیص روند تغییرات ارزش سهام با توجه به داده‌های جمع‌آوری شده در طول یک سال می‌تواند تحلیل سری زمانی نامیده شود.

سری زمانی و تحلیل سری زمانی

هدف: ►

کشف الگو رفتار داده ها در گذشته و پیش بینی رفتار آینده با
استفاده از داده های سری زمانی


سری زمانی

- ▶ متغیر تصادفی: در آمار و احتمال، متغیر تصادفی متغیری است که مقدار آن از اندازه‌گیری یک فرایندهای تصادفی بدست می‌آید.
- ▶ اگر فرآیند تصادفی، میزان فروش کارخانه باشد و متغیر t نشاندهنده زمان، متغیر تصادفی $X(t)$ میزان فروش کارخانه در ماه t را نشان می‌دهد.
- ▶ سری زمانی را می‌توان با متغیر تصادفی $X(t)$ نشان داد:
- ▶ $X(t) \quad t = 1, 2, 3, \dots$
- ▶ سری زمانی، برداری از داده‌ها که در فواصل زمانی مشخص دریافت و پرمحسوب زمان مرتب شده‌اند.

سری زمانی

$X = [22, 71, 74, 75, 75, 70, 76, 78, 82, 83, 82, \dots, 94]$

$t = [1, 2, 3, \dots, 36]$



انواع متغیر سری زمانی

▶ تک متغیره: یک ویژگی از فرآیند تصادفی مورد بررسی قرار می گیرد. به طور مثال



میزان فروش کلی یک کارخانه، قیمت نفت

▶ چند متغیره: بیشتر از یک ویژگی از فرآیند تصادفی مورد بررسی قرار می گیرد. به

طور مثال میزان فروش هر یک از محصولات کارخانه، قیمت سوختهای فسیلی به

تفکیک

انواع متغیر سری زمانی



انواع سری زمانی

- ▶ **گسسته:** برای سری زمانی $X(t)$ ، اگر نمونه‌برداری از فرآیند تصادفی به صورت گسسته انجام شود مثلاً ساعتی، روزانه، ماهانه و ... باشد آنگاه سری زمانی گسسته است. (مثلهایی که دیدیم همگی گسسته بودند.)
- ▶ **پیوسته:** اگر t پیوسته باشد، آنگاه سری زمانی $X(t)$ نیز پیوسته خواهد بود. به طور مثال دمای هوا و یا دبی رودخانه

انواع سری زمانی

- ▶ **گسسته:** برای سری زمانی $X(t)$ ، اگر نمونه‌برداری از فرآیند تصادفی به صورت گسسته انجام شود مثلاً ساعتی، روزانه، ماهانه و ... باشد آنگاه سری زمانی گسسته است. (مثلهایی که دیدیم همگی گسسته بودند.)
- ▶ **پیوسته:** اگر t پیوسته باشد، آنگاه سری زمانی $X(t)$ نیز پیوسته خواهد بود. به طور مثال دمای هوا و یا دبی رودخانه

مولفه‌های سری زمانی

▶ چهار ویژگی الگوی رفتاری یک سری زمانی:

▶ روند (trend)

▶ فصلی (seasonal)

▶ غیر معمول (irregular)

▶ تناوبی (cyclic)


مولفه‌های سری زمانی-روند

► تمایل سری زمانی به افزایش، کاهش یا حتی ثابت بودن، را روند سری زمانی گویند.

روند افزایشی




روند ثابت



روند کاهشی





مولفه‌های سری زمانی-روند



مولفه‌های سری زمانی – فصلی

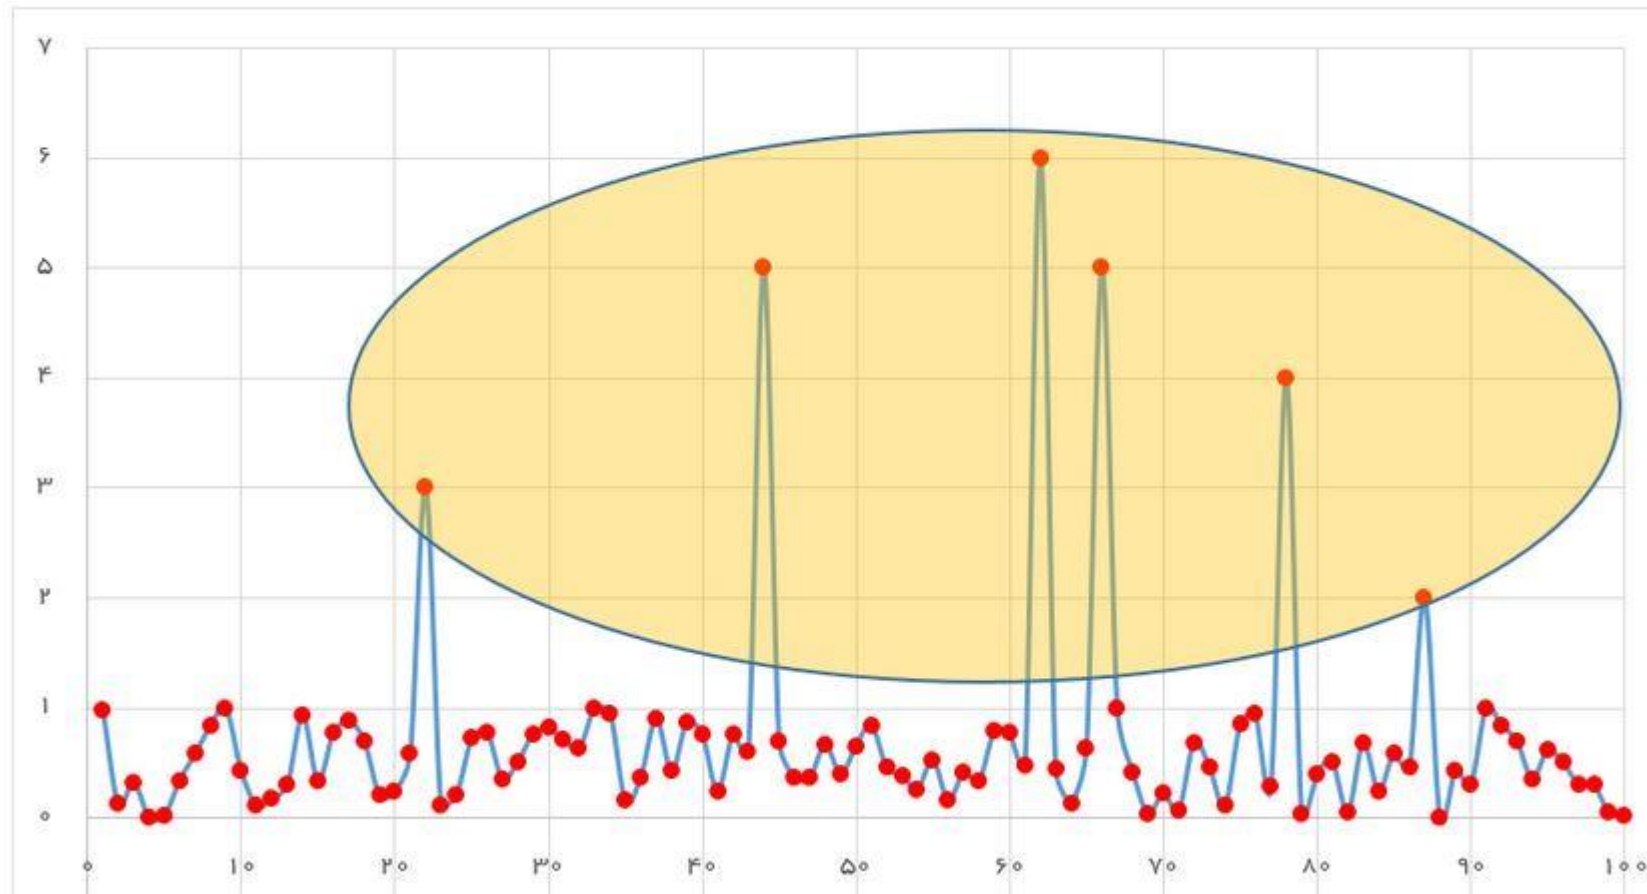
► فصلی: تغییراتی که در بازه‌های کوچک و با فواصل زمانی یکسان تکرار می‌شوند.



تغییرات فصلی در سری زمانی


مولفه‌های سری زمانی – غیر معمول

► غیر معمول: تغییراتی که قابل پیش‌بینی نیستند و نظم و الگوی خاصی ندارند.



مولفه‌های سری زمانی – تناوب

▶ تناوب: تغییرات یکسان و تکراری در مقاطع میان مدت، تناوب در سری زمانی نامیده می‌شود.



سری زمانی

- ▶ سری ایستا: یک سری زمانی است که قوانین حاکم بر تغییرات مقادارها، وابسته به زمان نباشد. قوانین احتمالی حاکم بر فرایند، با زمان تغییر نمی کند یا به عبارتی فرایند در تعادل آماری است.
- ▶ سری غیر ایستا: سری زمانی است که تغییرات آن در طول زمان متفاوت است و به زمان وابسته است بنابراین اطلاعات آماری ثابتی نخواهد داشت.


پیش بینی سری ایستا ساده تر است.

سری زمانی ایستا

➤ میانگین ثابت

➤ واریانس ثابت : اختلاف بین داده و میانگین وابسته به زمان نباشد.

➤ کوواریانس مستقل از زمان: تفاضل بین مقادیر ابتدا و انتهای بازه‌های ثابت وابسته به زمان نباشد.



تست ایستایی سری زمانی

▶ نگاه کردن به نمودار

▶ نتایج آماری

▶ تستی به نام **Augmented Dickey-Fuller (ADF)** وجود دارد.

▶ تست عددی را به عنوان نتیجه به ما می دهد که اگر صفر یا نزدیک به صفر باشد به معنای ایستایی بودن سری است.

مدل های تحلیل سری زمانی

► اگر $X(t)$ مقدار سری زمانی باشد و $T(t)$ اثر مولفه روند، $C(t)$ اثر مولفه تناوب، $S(t)$ اثر مولفه فصل و $I(t)$ انیز اثر مولفه تصادفی باشد، می توان این دو مدل سری زمانی را به صورت زیر معرفی کرد:

► «مدل ضربی» Multiplicative Model : $X(t) = T(t) \times S(t) \times C(t) \times I(t)$

► «مدل جمعی» Additive Model : $X(t) = T(t) + S(t) + C(t) + I(t)$

روش‌های ایستا کردن سری زمانی

► عملگر میانگین متحرک (Moving Average) :

► $X'(t) = [X(t) + X(t-1) + \dots + X(t-(k-1))]/k$

► $Y(t) = X(t) - X'(t)$

► تفاضل (differencing) :

► $d^1(t) = X(t) - X(t-1)$, $d^1(t-1) = X(t-1) - X(t-2)$, ...

► $d^2(t) = d^1(t) - d^1(t-1)$, $d^2(t-1) = d^1(t-1) - d^1(t-2)$, ...

ویژگی خود همبستگی (AutoCorrelation)

- ▶ هدف از تحلیل سری زمانی، یافتن رابطه بین داده‌های زمانهای مختلف است.
- ▶ خود همبستگی: وابستگی بین مقدار دنباله‌ای بر حسب زمان است.
- ▶ تابعی که خود همبستگی را بر حسب یک فاصله زمانی بین مشاهدات محاسبه می‌کند «تابع خود همبستگی» (Autocorrelation Function) نامیده می‌شود.
- ▶ Lag: فاصله بین دو داده در سری زمانی

تابع خود همبستگی (AutoCorrelation Function-ACF)


► فرض کنید X_t مقدار سری زمانی در زمان t باشد.

► تابع خود همبستگی برای این سری زمانی، ضرایب همبستگی بین مشاهدات X_t و X_{t-h} را بر اساس $h=1,2,3,\dots$ نشان می‌دهد:


$$ACF = \frac{Cov(X_t, X_{t-h})}{\sigma_t \sigma_t}$$

$$ACF = \frac{Cov(X_t, X_{t-h})}{Var(X_t)}$$

خود همبستگی




خود همبستگی



خود همبستگی جزئی (Partial AutoCorrelation)

- ▶ وابستگی مستقیم بین دو داده را بیان می کند.
- ▶ در خودهمبستگی، وابستگی های غیر مستقیم هم دخیل هستند اما در خودهمبستگی جزئی وابستگی غیر مستقیم حذف می شود.
- ▶ این ویژگی رابطه بین دو داده را طوری بیان می کند که با هیچ lag کوچکتري قابل بیان نیست.

خود همبستگی جزئی (Partial AutoCorrelation)



خود همبستگی و خود همبستگی جزئی

- ▶ از ویژگی خود همبستگی برای انتخاب مدل سری زمانی استفاده می‌شود.
- ▶ از ویژگی خود همبستگی جزئی برای تعیین پارامترهای مدل استفاده می‌شود.

داده‌ها و تخمین پارامترهای مدل

▶ داده سری زمانی: $X(t)$

▶ تخمین داده‌ها: $Y(t)$

▶ مدل: $Y = f(X, t, \alpha)$

▶ بنابراین برای هر t ، دو مقدار $X(t)$ و $Y(t)$ وجود دارد که اولی حاصل اندازه‌گیری از فرآیند تصادفی و دومی از مدل به دست آمده.

▶ این دو مقدار به دلایلی (مناسب نبودن مدل، نویز...) با هم تفاوت دارند که به آن مانده (residual) گویند:

▶
$$r(t) = Y(t) - X(t)$$

داده‌ها و تخمین پارامترهای مدل

▶ در یادگیری ماشین همواره هدف این است که مانده کمینه شود.

▶ بنابراین تابع هدف شکل می‌گیرد:

▶ $\text{Min } r(t)$

▶ در سری زمانی معمولاً از روش کمترین مربعات استفاده می‌شود:

▶
$$\text{Cost}(\alpha) = \sum_t r(t)^2 = \sum_t (X(t) - Y(t))^2 = \sum_t (X(t) - f(X, t, \alpha))^2$$

▶ هدف کمینه کردن تابع Cost هست. پارامترهای α طوری تعیین می‌شوند این تابع کمینه شود.

▶ می‌خواهیم نقطه کمینه یک تابع را به دست آوریم: از تابع مشتق می‌گیریم و برابر صفر قرار می‌دهیم.

داده‌ها و تخمین پارامترهای مدل

- ▶ با مشخص شدن پارامترها α ، می‌توان $Y(t)$ را به دست آورد.
- ▶ برای این مرحله که فیت کردن مدل با داده گویند از داده‌های آموزش استفاده می‌شود.
- ▶ برای سنجش مدل از داده‌های تست استفاده می‌شود.
- ▶ بسته به کاربرد، روشهای مختلفی برای سنجش استفاده می‌شود.

مدل اتو رگرسیو (AR)

- ▶ یک مدل خطی است (؟).
- ▶ زمانی قابل استفاده است که داده‌های سری زمانی ویژگی خود همبستگی داشته باشند.
- ▶ بر اساس داده‌های زمانی قبلی، داده زمانی فعلی را تخمین می‌زند.
- ▶ مرتبه k : بر اساس k تأخیر (لگ)، تخمین صورت می‌گیرد.

مدل اتو رگرسیو (AR)

▶ مرتبه 1:

▶ $Y(t) = C + \varphi_1 X(t - 1)$

▶ مرتبه p:

▶ $Y(t) = C + \varphi_1 X(t - 1) + \varphi_2 X(t - 2) + \dots + \varphi_p X(t - p) = C + \sum_{i=1}^p \varphi_i X(t - i)$

▶ $r(t) = Y(t) - X(t)$

▶ هر چه ضرایب φ_i کوچکتر باشند یعنی وابستگی کمتری بین داده ای که تخمین می زنیم و داده های قبلی وجود دارد و بالعکس.

▶ $-1 \leq \varphi_i \leq 1$


مدل اتو رگرسیو (AR)

- ▶ `import pandas as pd`
- ▶ `import matplotlib.pyplot as plt`
- ▶ `from statsmodels.tsa.stattools import adfuller`
- ▶ `from statsmodels.graphics.tsaplots import plot_acf`
- ▶ `from statsmodels.graphics.tsaplots import plot_pacf`
- ▶ `from statsmodels.tsa.ar_model import AutoReg`
`statsmodels.tsa.ar_model import AutoReg`

مدل اتو رگرسیون (AR)

- ▶ `from statsmodels.tsa.ar_model import AutoReg`
- ▶ `df = pd.read_csv("BD.csv")`
- ▶ `df['Date'] = pd.to_datetime(df['Date'],)`
- ▶ `df.set_index('Date', inplace = True)`
- ▶ `size = round(len(df)*.8)`
- ▶ `X_tr = df.iloc[:size]`
- ▶ `X_te = df.iloc[size:]`
- ▶ `result = adfuller(X_tr)`
- ▶ `print(result)`
- ▶ `plot_acf(X_tr, lags=30)`
- ▶ `plot_pacf(X_tr, lags=30)`
- ▶ `ar = AutoReg(X_tr, lags =3).fit()`
- ▶ `print (ar.summary())`

مدل اتو رگرسیو (AR)



مدل اتو رگرسیو (AR)

result - Tuple (6 elements)

Ind	Type	Size	Value
0	float64	1	-3.41377339551857
1	float64	1	0.010498203476885785
2	int	1	7
3	int	1	284
4	dict	3	{'1%':-3.4535872903895797, '5%':-2.871771355211212, '10%':-2.572221728 ...}
5	float64	1	1868.9845862033646

Close

مدل اتو رگرسیو (AR)

```
warning that no frequency information was
AutoReg Model Results
=====
Dep. Variable:      Births      No. Observations:      292
Model:             AutoReg(3)   Log Likelihood         -984.610
Method:            Conditional MLE S.D. of innovations    7.301
Date:              Sun, 13 Mar 2022 AIC                        4.011
Time:              16:53:25      BIC                     4.074
Sample:            01-04-1959    HQIC                    4.036
                  - 10-19-1959
=====
              coef      std err          z      P>|z|      [0.025      0.975]
-----
intercept      28.3384      3.546      7.992      0.000      21.388      35.288
Births.L1       0.1650      0.059      2.817      0.005       0.050       0.280
Births.L2       0.0987      0.059      1.673      0.094      -0.017       0.214
Births.L3       0.0593      0.058      1.015      0.310      -0.055       0.174
=====
                        Roots
=====
              Real      Imaginary      Modulus      Frequency
-----
AR.1           1.8339      -0.0000j      1.8339      -0.0000
AR.2          -1.7489      -2.4775j      3.0326      -0.3478
AR.3          -1.7489      +2.4775j      3.0326       0.3478
=====
```


مدل اتو رگرسیو (AR)

Dep. Variable:	Births	No. Observations:	292
Model:	AutoReg(7)	Log Likelihood	-962.973
Method:	Conditional MLE	S.D. of innovations	7.099
Date:	Sun, 13 Mar 2022	AIC	3.983
Time:	16:59:53	BIC	4.098
Sample:	01-08-1959	HQIC	4.029
	- 10-19-1959		

	coef	std err	z	P> z	[0.025	0.975]
intercept	18.8197	4.599	4.092	0.000	9.805	27.835
Births.L1	0.1453	0.058	2.505	0.012	0.032	0.259
Births.L2	0.0637	0.058	1.093	0.275	-0.051	0.178
Births.L3	0.0307	0.058	0.527	0.598	-0.084	0.145
Births.L4	0.0304	0.058	0.521	0.603	-0.084	0.145
Births.L5	0.0473	0.058	0.813	0.416	-0.067	0.161
Births.L6	0.0397	0.058	0.684	0.494	-0.074	0.154
Births.L7	0.1955	0.058	3.372	0.001	0.082	0.309

Roots				
	Real	Imaginary	Modulus	Frequency
AR.1	1.1371	-0.0000j	1.1371	-0.0000
AR.2	0.7784	-0.9854j	1.2557	-0.1436
AR.3	0.7784	+0.9854j	1.2557	0.1436
AR.4	-1.1650	-0.5672j	1.2958	-0.4279
AR.5	-1.1650	+0.5672j	1.2958	0.4279
AR.6	-0.2835	-1.2723j	1.3035	-0.2849
AR.7	-0.2835	+1.2723j	1.3035	0.2849

مدل اتو رگرسیو (AR)



مدل میانگین متحرک (MA)

- ▶ در این مدل تأثیر شوکهای تصادفی در نظر گرفته می‌شود.
- ▶ فاصله بین مقدار خود همبستگی و مقدار سری، شوک تصادفی را نشان می‌دهد.
- ▶ در نمودار خود همبستگی متوجه می‌شویم که داده‌ها حدود چند لگ تحت تأثیر یکدیگر هستند.
- ▶ از همین ویژگی می‌توان فهمید که شوکهای ناگهانی تا چند لگ بعدی تأثیر می‌گذارند.

مدل میانگین متحرک (MA)

▶ مرتبه 1:

▶ $Y(t) = \mu + \theta_1 r(t - 1)$

▶ مرتبه q:

▶ $Y(t) = \mu + \theta_1 r(t - 1) + \theta_2 r(t - 2) + \dots + \theta_q r(t - q) = \mu + \sum_{i=1}^q \theta_i r(t - i)$

▶ $\varepsilon_t = Y(t) - X(t)$


▶ هر چه ضرایب θ_i کوچکتر باشند یعنی وابستگی کمتری بین داده ای که تخمین می زنیم و مانده های قبلی وجود دارد و بالعکس.

▶ $-1 \leq \theta_i \leq 1$

مدل میانگین متحرک (MA)

- ▶ `from statsmodels.tsa.arima_model import ARMA`
- ▶ `ma = ARMA(X_tr, order=(0,3)).fit()`
- ▶ `print(ma.summary())`

مدل میانگین متحرک (MA)



مدل میانگین متحرک (MA)

```

=====
Dep. Variable:          Births      No. Observations:          292
Model:                ARMA(0, 3)   Log Likelihood              -996.002
Method:               css-mle      S.D. of innovations         7.330
Date:                 Sun, 13 Mar 2022  AIC                2002.005
Time:                  17:16:14      BIC                2020.388
Sample:               01-01-1959     HQIC               2009.368
                   - 10-19-1959
=====

```

	coef	std err	z	P> z	[0.025	0.975]
const	41.7097	0.584	71.431	0.000	40.565	42.854
ma.L1.Births	0.1724	0.058	2.958	0.003	0.058	0.287
ma.L2.Births	0.1195	0.056	2.123	0.034	0.009	0.230
ma.L3.Births	0.0715	0.060	1.196	0.232	-0.046	0.189

```

=====
                        Roots
=====

```

	Real	Imaginary	Modulus	Frequency
MA.1	0.5134	-2.2181j	2.2768	-0.2138
MA.2	0.5134	+2.2181j	2.2768	0.2138
MA.3	-2.6989	-0.0000j	2.6989	-0.5000

```

=====

```


مدل میانگین متحرک (MA)

=====						
Dep. Variable:	Births	No. Observations:	292			
Model:	ARMA(0, 7)	Log Likelihood	-991.424			
Method:	css-mle	S.D. of innovations	7.213			
Date:	Sun, 13 Mar 2022	AIC	2000.847			
Time:	17:17:46	BIC	2033.938			
Sample:	01-01-1959	HQIC	2014.102			
	- 10-19-1959					
=====						
	coef	std err	z	P> z	[0.025	0.975]

const	41.7029	0.647	64.428	0.000	40.434	42.972
ma.L1.Births	0.1211	0.061	1.995	0.046	0.002	0.240
ma.L2.Births	0.0877	0.062	1.424	0.154	-0.033	0.208
ma.L3.Births	0.0261	0.062	0.418	0.676	-0.096	0.148
ma.L4.Births	0.0248	0.053	0.467	0.640	-0.079	0.129
ma.L5.Births	0.0630	0.054	1.163	0.245	-0.043	0.169
ma.L6.Births	0.0341	0.061	0.563	0.573	-0.085	0.153
ma.L7.Births	0.1844	0.065	2.835	0.005	0.057	0.312
Roots						
=====						
	Real	Imaginary	Modulus	Frequency		

MA.1	1.1028	-0.6226j	1.2664	-0.0818		
MA.2	1.1028	+0.6226j	1.2664	0.0818		
MA.3	-1.2607	-0.0000j	1.2607	-0.5000		
MA.4	-0.7846	-1.0023j	1.2728	-0.3557		
MA.5	-0.7846	+1.0023j	1.2728	0.3557		
MA.6	0.2197	-1.2676j	1.2865	-0.2227		
MA.7	0.2197	+1.2676j	1.2865	0.2227		

مدل میانگین متحرک (MA)



مدل ARMA

► ترکیبی از روش $MA(p)$ و $AR(q)$ هست.

► $ARMA(p,q)$:

►
$$Y(t) = \mu + \sum_{i=1}^p \varphi_i X(t-i) + \sum_{i=1}^q \theta_i r(t-i)$$

►
$$\varepsilon_t = Y(t) - X(t)$$

► هر چه ضرایب φ_i کوچکتر باشند یعنی وابستگی کمتری بین داده ای که تخمین می زنیم و داده های قبلی وجود دارد و بالعکس.

►
$$-1 \leq \varphi_i \leq 1$$

مدل ARMA


ترکیبی از روش $MA(p)$ و $AR(q)$ هست.

$ARMA(p,q)$:

► $Y(t) = C + \sum_{i=1}^p \varphi_i X(t-i) + \sum_{i=1}^q \theta_i r(t-i)$


► $ARMA(2,1) = C + \varphi_1 X(t-1) + \varphi_2 X(t-2) + \theta_1 r(t-1)$

مدل ARMA



Differentiation

Actual Series



Series After
Differentiation



مدل ARIMA

► ترکیبی از روش $MA(p)$ و $AR(q)$ و $Dif(d)$ هست.

► $ARIMA(p,d,q)$:

► $ARIMA(2,0,1) = C + \varphi_1 X(t-1) + \varphi_2 X(t-2) + \theta_1 r(t-1)$